

기본 상황

X : data z : latent vector

가정: X 는 어떠한 과정을 통해 z 로부터 생성되었다.

① $z^{(i)}$ 는 어떤 사전확률 분포 $p_\theta(z)$ 로 부터 나왔다.

② $x^{(i)}$ 는 어떤 조건부 확률인 $p_\phi(x|z)$ 로 부터 생성되었다.

모든 PDF는 θ 와 z 에 대해서 미분가능하다.

하지만 θ 와 z 가 무지는 모른다.

기준에 존재했던 확률분포 추론은 두 가지 문제점이 있었다.

① Intractability

marginal probability 인 $p_\theta(x)$ 와 참 사후확률 $p_\theta(z|x)$

그리고 이를 위한 알고리즘이(적분) 모두 intractable (복잡)하다.

② A large dataset

기준의 배치 학습이 너무 저효율이다. (너무 느리다)

논문에서 제안하는 것들. (우리가 관심있는 것들)

① 모두 θ 추론을 위한 효율적인 ML 이나 MAP 방법

② 사후확률을 효율적으로 추정하고 싶다 ($p(z|x)$)

③ marginal probability $p(x)$ 를 효율적으로 추정하고 싶다.

<Content>

x 의 marginal likelihood = $\sum \log p_\theta(x^{(i)})$

다시쓰면 $\log p_\theta(x^{(i)}) = \underbrace{D_{KL}(q_\phi(z|x^{(i)}) || p_\theta(z|x^{(i)})) + \mathcal{L}(\theta, \phi; x^{(i)})}$

추정 사후 확률과 참 사후 확률의 차이 ≥ 0

따라서 lower bound를 구할 수 있음

$$\log p_{\theta}(x^{(i)}) \geq \mathcal{L}(\theta, \phi; x^{(i)}) \quad \leftarrow \text{최대화해야 좋다 (Lower bound 효과)}$$

$$\textcircled{1} \dots = E_{q_{\phi}(z|x)} [-\log q_{\phi}(z|x) + \log p_{\theta}(x, z)]$$

$$\textcircled{2} \dots = -D_{KL}(q_{\phi}(z|x^{(i)}) \| p_{\theta}(z)) + E_{q_{\phi}(z|x^{(i)})} [\log p_{\theta}(x^{(i)}|z)]$$

이 상제미시 Monte Carlo Method를 사용하면 분산이 커짐.

- ① $z \sim q_{\phi}(z|x)$ 를 따르는 분포에서 noise를 넣어서 z 를 L 개 추출한다. 다시 말하면 noise는 $\epsilon \sim p(\epsilon)$ 이고 이를 이용해 $g_{\phi}(\epsilon, x)$ 를 추출함수라고 생각하면 $z = g_{\phi}(\epsilon, x)$ 이다. 그러면 $\mathcal{L}(\theta, \phi; x)$ 를 다음과 같이 근사할 수 있다. \rightarrow reparameterization trick

$$\mathcal{L}^A(\theta, \phi; x^{(i)}) = \frac{1}{L} \sum_{l=1}^L (\log p_{\theta}(x^{(i)}, z^{(i,l)}) - \log q_{\phi}(z^{(i,l)}|x^{(i)}))$$

- ② $D_{KL}(\cdot)$ 부분이 analytically integrate 할 수 있다면 (appendix B에 있음) $E[\cdot]$ 부분만 샘플링 과정을 거치면 된다. 식으로 쓰면 아래와 같다

$$\mathcal{L}^B(\theta, \phi; x^{(i)}) = \underbrace{-D_{KL}(q_{\phi}(z|x^{(i)}) \| p_{\theta}(z))}_{\text{Regularization}} + \underbrace{\frac{1}{L} \sum_{l=1}^L (\log p_{\theta}(x^{(i)}|z^{(i,l)}))}_{\text{Reconstruction Error}}$$

VAE관계:

Regularization

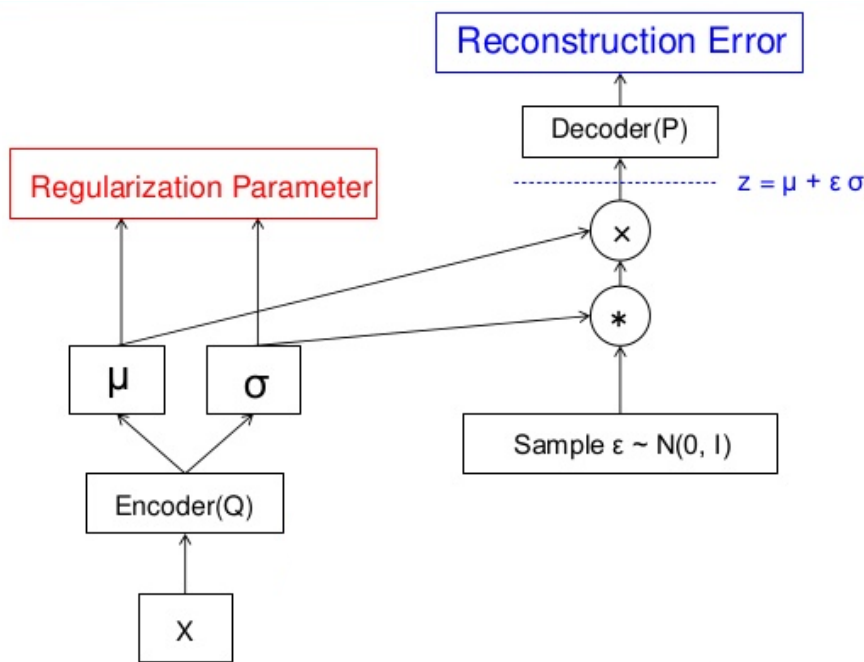
Reconstruction Error

* reparameterization trick 사용조건

- ① CDF가 추적가능해야 한다
- ② 정규분포랑 비슷하게 "location-scale" 한 분포여야 한다. 즉 정규분포처럼 location \rightarrow mean scale \rightarrow std 가 될 수 있어야 한다.
- ③ 합성분포 가능해야 (e.g. log-normal..)

이렇게 ;;;

<VAE>



① forward

데이터 x 가 Encoder를 거쳐서 latent vector의 μ 와 σ 를 추출한다. reparameterization trick을 사용해 $\epsilon \sim N(0, I)$ 를 transform 한다.

(이렇게 해야 복원 loss로 부터 Encoder 학습 가능)
transformed 값을 Decoder를 통해 복원한다.

② backward

위에서 증명한 \tilde{L} 을 loss값으로 해서
backpropagation을 진행한다.