

<단행배경>

Reviewer: 김정학

'Latent ODEs for Irregularly-Sampled Time Series'의 논문과 마찬가지를 아울러 특성을 가지고 있는 시계열 데이터를 해결하기 위해서 나온게 됐다.

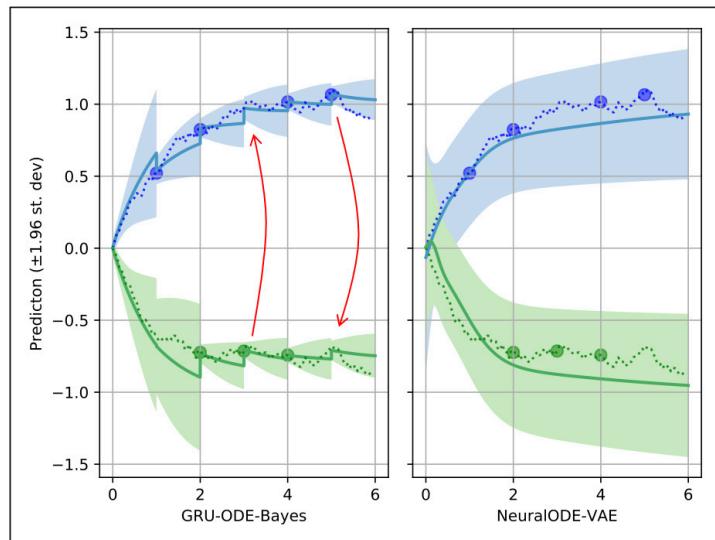
이 논문에서는 두 가지 method를 제시한다.

① continuous time version of GRU

→ 기존 GRU는 discrete 흐름에 수식을 통해서 GRU의 ode func를 조작하였다.

② Bayesian update network

→ 데이터가 없는 부분은 ODE로 적용하고 데이터가 있는면 GRU로 hidden layer를 업데이트한다.



이를 기반으로 주제한 모델은 두 가지 장점이 있다.

① 빠르게 모델을 추정한다.

② 변수간의 상관관계까지 배운다. 예를 들어 한 변수에서

관측치가 발견되면 다른 변수에 영향을 주는 것을 확인할 수 있다 (red arrow)

학습하는 데이터는 SDE를 따른다고 가정한다 (일반적이라고 한다.)

$$dY(t) = \mu(Y(t))dt + \sigma(Y(t))dW(t) \quad \text{이고}$$

논문의 모델이 $\mu(Y(t))$ 와 $\sigma(Y(t))$ 를 학습하는 것이 목표이다.

<모델 구현 및 학습>

① GRU-ODE

위에서 언급했듯이 GRU를 continuous하게 바꿀 것이다.

우리가 알고 있는 GRU는 아래다.

$$\text{reset gate } r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)$$

$$\text{update gate } z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)$$

$$\text{update vector } g_t = \tanh(W_h x_t + U_h (r_t \odot h_{t-1}) + b_h)$$

GRU의 hidden state $h_t = z_t \odot h_{t-1} + (1 - z_t) \odot g_t$ 이고

$$\begin{aligned}\Delta h_t &= h_t - h_{t-1} = z_t \odot h_{t-1} + (1 - z_t) \odot g_t - h_{t-1} \\ &= (1 - z_t) \odot (g_t - h_{t-1}) \text{ 이므로}\end{aligned}$$

마분방점식은

$$\frac{dh(t)}{dt} = (1 - z(t)) \odot (g(t) - h(t)) \text{ 이다.}$$

이렇게 주하면 ODE Func로 사용할 수 있다. !

추가로 만약 고속치의 변수 중에 연속적 데이터가 있다면 그는 위

GRU-ODE에 $g(t)$ 로 넣어주기만 하면 된다. 그러면 안 넣으면 그만.

이런 GRU-ODE는 특징이 있다.

① Boundness

hidden state가 $[-1, 1]$ 범위내에서만 변동한다. ($[-1, 1]$ 범위에서 시작한다고 해도)

② Continuity

$h(t)$ 가 연속적이다.

③ General numerical Integration

제일 먼저 step-size를 adaptive하게 바꾸는 기본기를 사용할 수 있다.

[2] GRU-Bayes

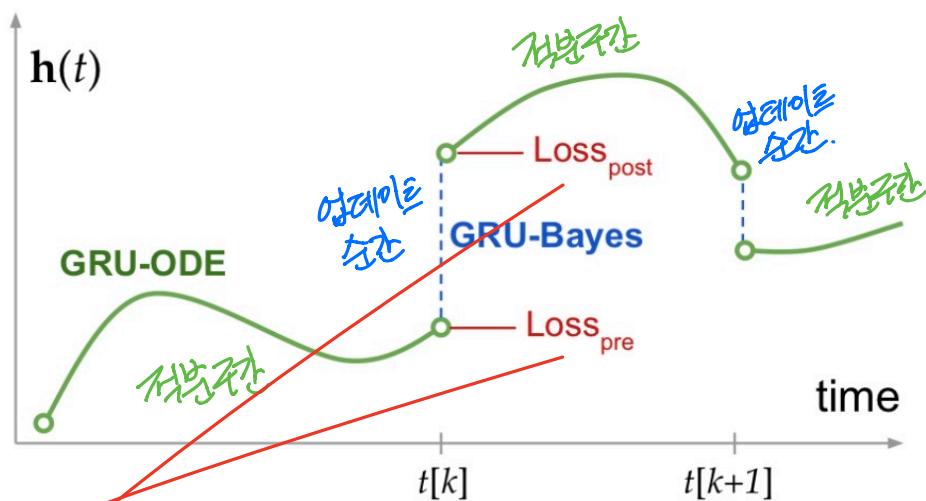
II은 ODE로 적용하는 부분이고 이전 업데이트하는 부분이다.

관측치가 있는 시간까지 도달했을 때, 업데이트를 한다. 이를 다음과 같다.

$$h(t+) = \text{GRU}(h(t-), f(y[k], m[k], h(t-)))$$

GRU에 들어가는 인풋은 업데이트 전의 하든 베터 $h(t-)$ 와
그 시간에 따른 관측치 $y[k]$ 와 mask vector $m[k]$ 와 $h(t-)$
를 preprocessing 하는 함수 f 의 결과값이다.

종합해선 can 모델의 forward 패드



[3] Loss 값

Loss_{pre} : 업데이트하기 전에 관측값 y 를 잘 나타내는지
negative log likelihood 사용

$$\text{Loss}_{\text{pre}} = - \sum_{j=1}^D m_j \log p(y_j | \theta = f_{\text{obs}}(\mathbf{h}_-)_j),$$

$\text{Loss}_{\text{post}}$: 업데이트한 후의 확률분포와

$P_{\text{Bayes}} \propto P_{\text{pre}} \cdot P_{\text{obs}}$ 분포의 차이를 loss로 사용

\rightarrow Bayesian update를 모델이 풀어낼 수 있게 학습

$$\text{Loss}_{\text{post}} = \sum_{j=1}^D m_j D_{KL}(p_{\text{Bayes},j} || p_{\text{post},j}).$$

• 2024-03-28

Algorithm 1 GRU-ODE-Bayes

Input: Initial state \mathbf{h}_0 ,
 observations \mathbf{y} , mask \mathbf{m} ,
 observation times \mathbf{t} , final time T .
 Initialize time = 0, loss = 0, $\mathbf{h} = \mathbf{h}_0$.
for $k = 1$ **to** K **do**

- {ODE evolution to $\mathbf{t}[k]$ }
- $\mathbf{h} = \text{GRU-ODE}(\mathbf{h}, \text{time}, \mathbf{t}[k])$
- time = $t[k]$
- {Pre-jump loss}
- loss += $\text{Loss}_{\text{pre}}(\mathbf{y}[k], \mathbf{m}[k], \mathbf{h})$
- {Update}
- $\mathbf{h} = \text{GRU-Bayes}(\mathbf{y}[k], \mathbf{m}[k], \mathbf{h})$
- {Post-jump loss}
- loss += $\lambda \cdot \text{Loss}_{\text{post}}(\mathbf{y}[k], \mathbf{m}[k], \mathbf{h})$

end for
 {ODE evolution to T }
 $\mathbf{h} = \text{GRU-ODE}(\mathbf{h}, \mathbf{t}[N_K], T)$
return (\mathbf{h} , loss)
